ИНСТИТУТ ДОПОЛНИТЕЛЬНОГО ОБРАЗОВАНИЯ
УНИВЕРСИТЕТА ИННОПОЛИС

УНИВЕРСИТЕТ ИННОПОЛИС

Итоговая аттестационная работа на тему: «Система поиска заимствований в учебно-методических работах НПР ИРНИТУ»

Лукьянов Н.Д.

г. Иркутск, 2026

Постановка задачи

Существующая в ИРНИТУ система эффективного контракта предполагает выполнение определенных работ НПР, однако достаточно часто, преподаватели с целью выполнения контракта занимаются переизданием/перефразированием уже изданных работ, что в свою очередь ведет к ухудшению учебных материалов. Оценкой работ занимается Методический совет ИРНИТУ, однако на очном заседании невозможно качественно провести подобную проверку.

Система предназначена для загрузки и проверки на наличие заимствований в работах НПР ИРНИТУ для поддержки принятия решений Методическим советом ИРНИТУ при назначении стимулирующих выплат в рамках эффективного контракта.

Проверка осуществляется на базе заранее загруженного и обработанного корпуса текстов путем вычисления эмбеддингов моделью BERT, с целью ускорения поиска планируется использование векторной БД.

https://datadojo.dev/2020/08/31/the-intuition-of-word-embeddings-how-you-teach-a-computer-to-understand-text/

Цель и задачи проекта

Цель: повышение качества создаваемых в ИРНИТУ учебно-методических работ, за счет внедрения автоматизированной системы предварительной оценки качества текста.

Задачи:

1. Предварительные исследования подобных решений и применяемых алгоритмов;
2. Выбор подходящего алгоритма и технологий его реализации;
3. Проектирование архитектуры приложения;
4. Реализация и тестирование;
5. Развертывание приложения на удаленном сервере.

Алгоритмическая постановка задачи

В общем виде задача поиска схожести тестов может быть представлена в следующем виде:

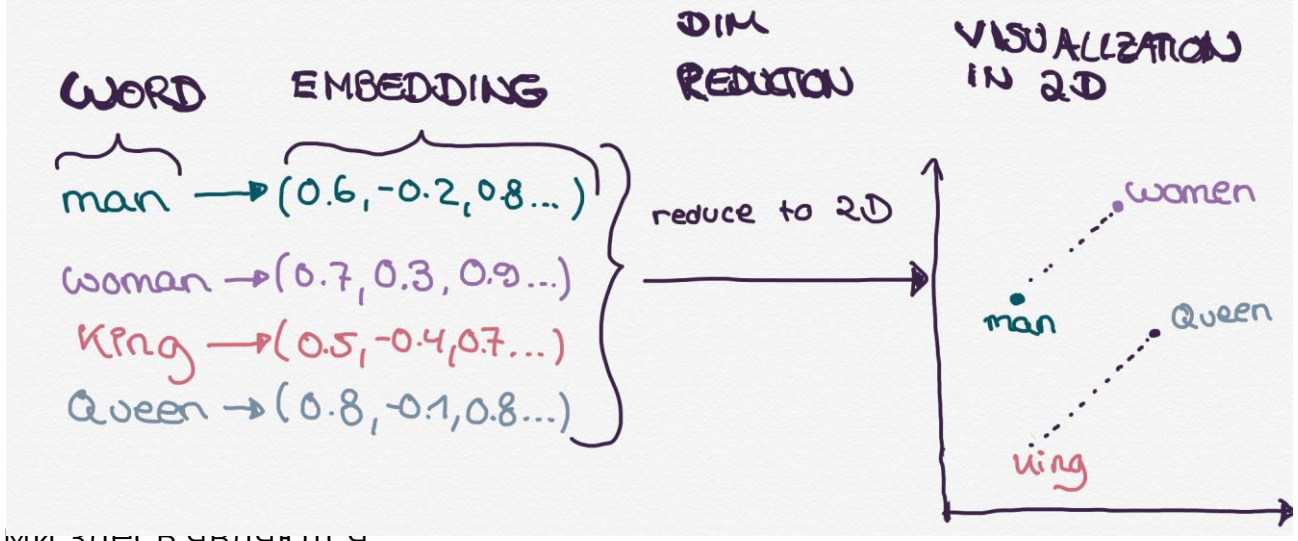

Ключевыми моментами здесь являются:

1. Способ расчета эмбеддингов;
2. Метрика расчета близости полученных эмбеддингов.

Предобработка данных

В рамках второй промежуточной аттестации был разработан и протестирован на реальных данных (11 учебно-методических работ и 20+ тезисов конференции) pipeline предобработки исследуемых текстов.

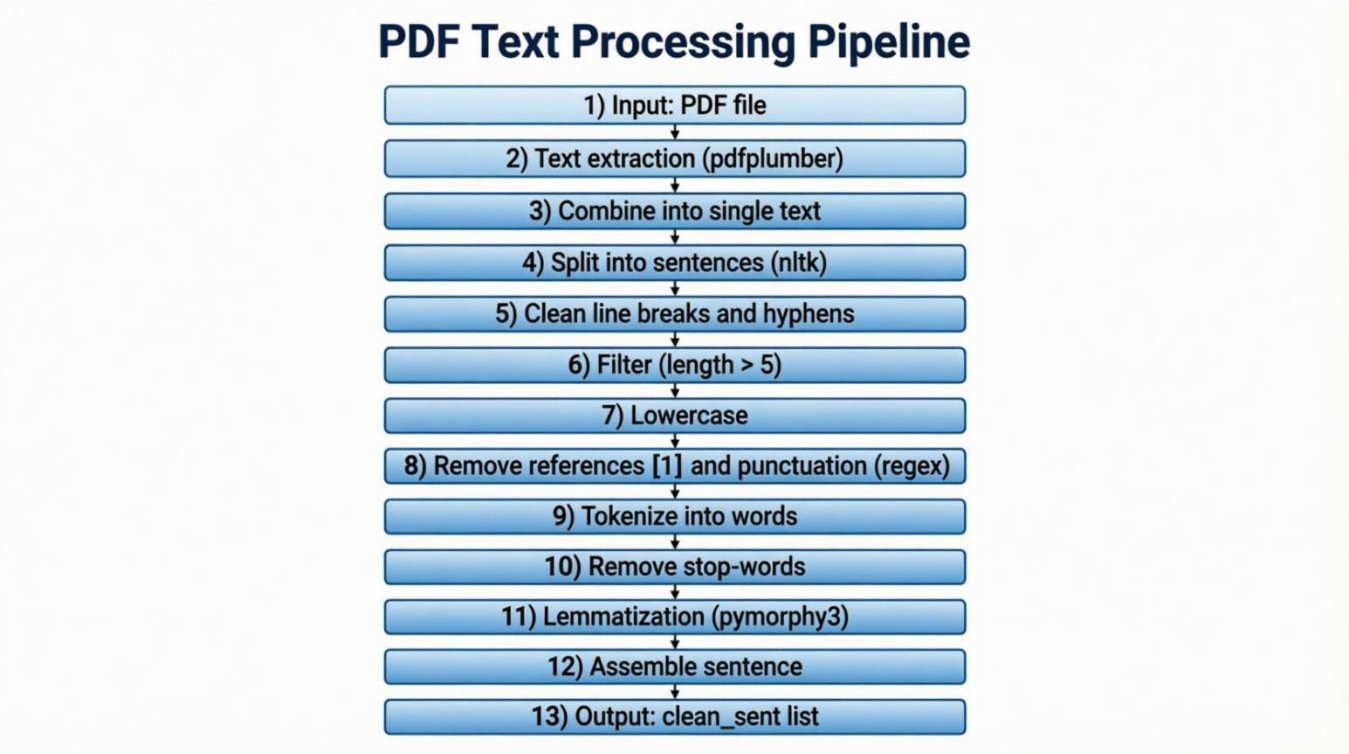

Исследуемые алгоритмы

На выбранных данных были протестированы два способа расчета эмбеддингов и поиска схожести:

1. TfidfVectorizer из библиотеки sklearn;
2. DeepPavlov/rubert-base-cased (модель BERT).

Результат представлен в таблице:

Критерий	TfidfVectorizer	BERT
Необходимость дообучения	Требуется	Не требуется
Корректность расчета	Уверенность в случае явного плагиата ~65%	Уверенность в случае явного плагиата ~85%
Скорость	Низкая, проверка реальной работы из 2900 предложений > 7 часов	Гораздо быстрее, та же работа ~2.5 часа

В результате исследования для дальнейшей работы была выбрана модель BERT

ИНСТИТУТ
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
УНИВЕРСИТЕТА ИННОПОЛИС

Проектирование и разработка

Архитектура приложения

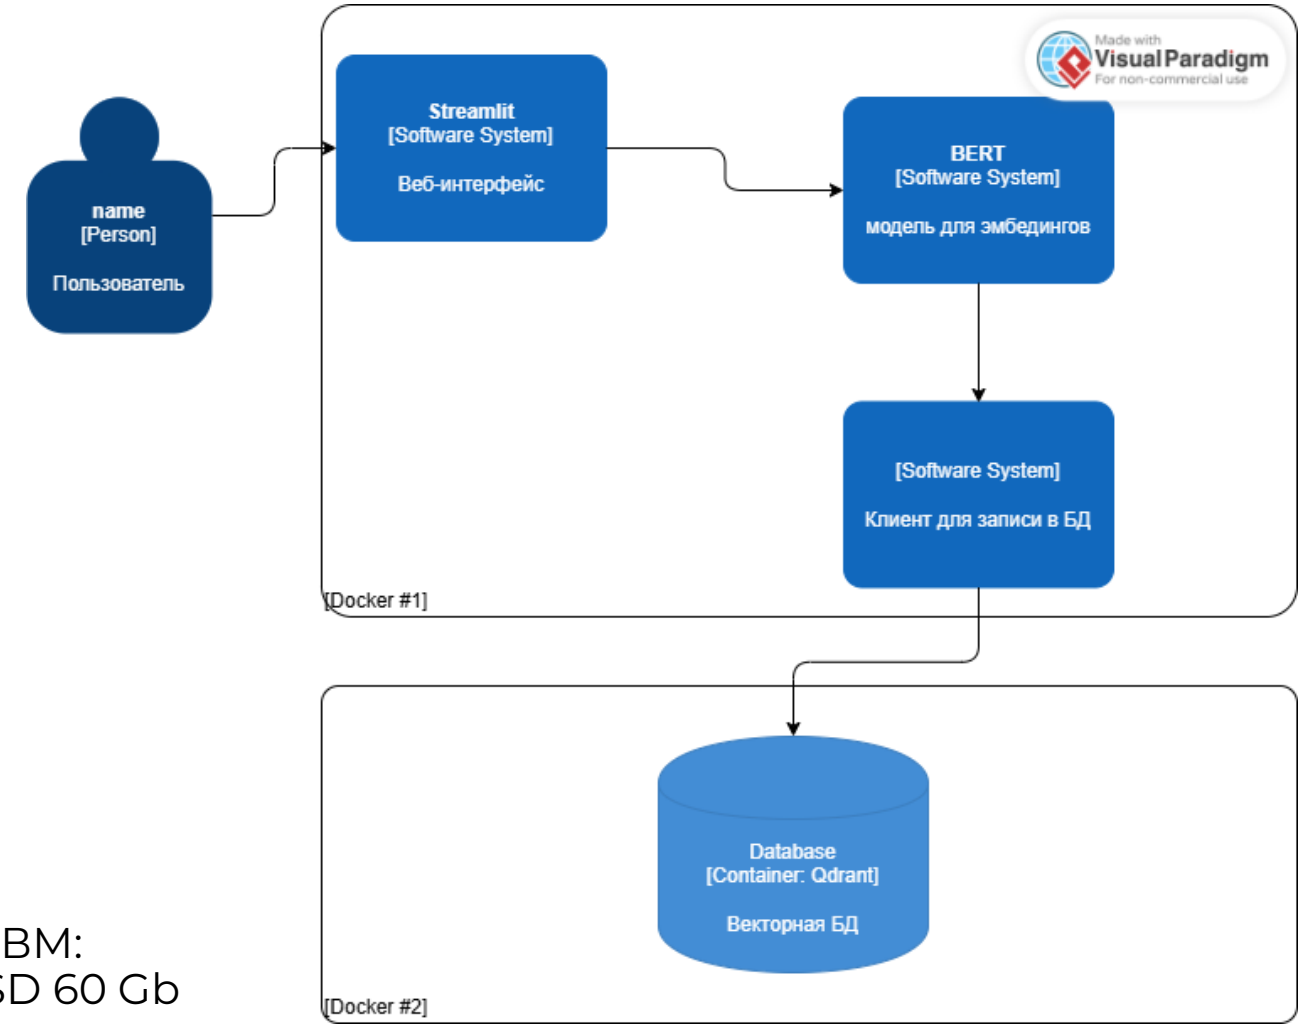

Характеристики ВМ:
8 CPU, 16 RAM, SSD 60 Gb

Стек использованных технологий

python™

docker®

Streamlit

Yandex Cloud

Интерфейсы приложения
Начальная страница

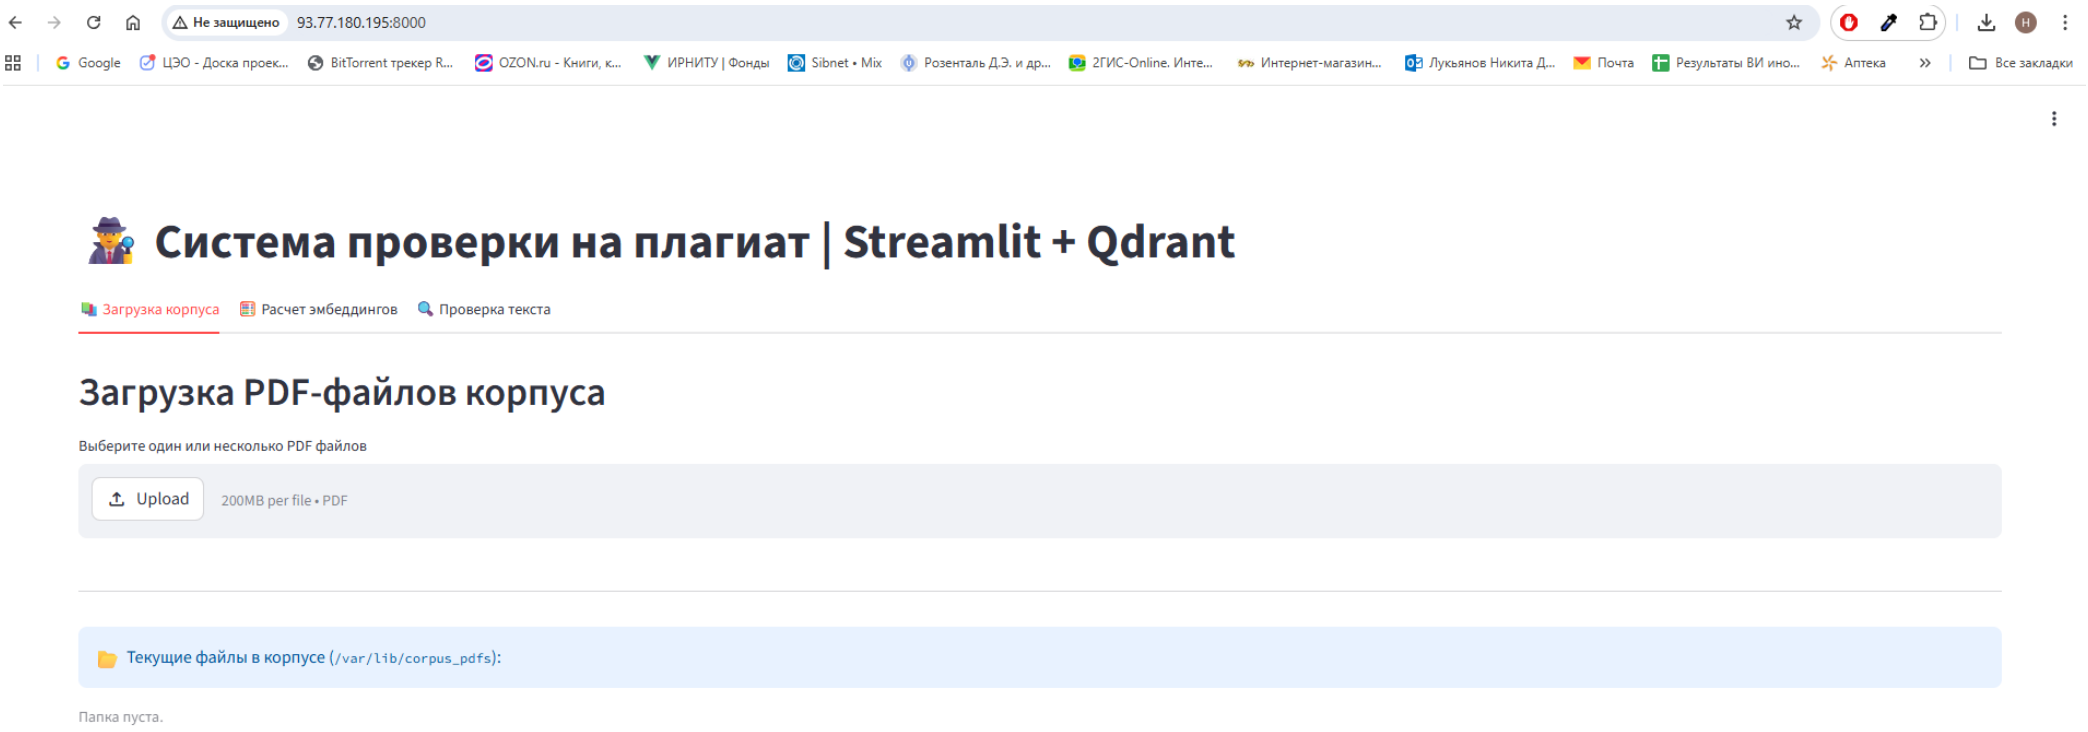

Интерфейсы приложения
Расчет эмбеддингов

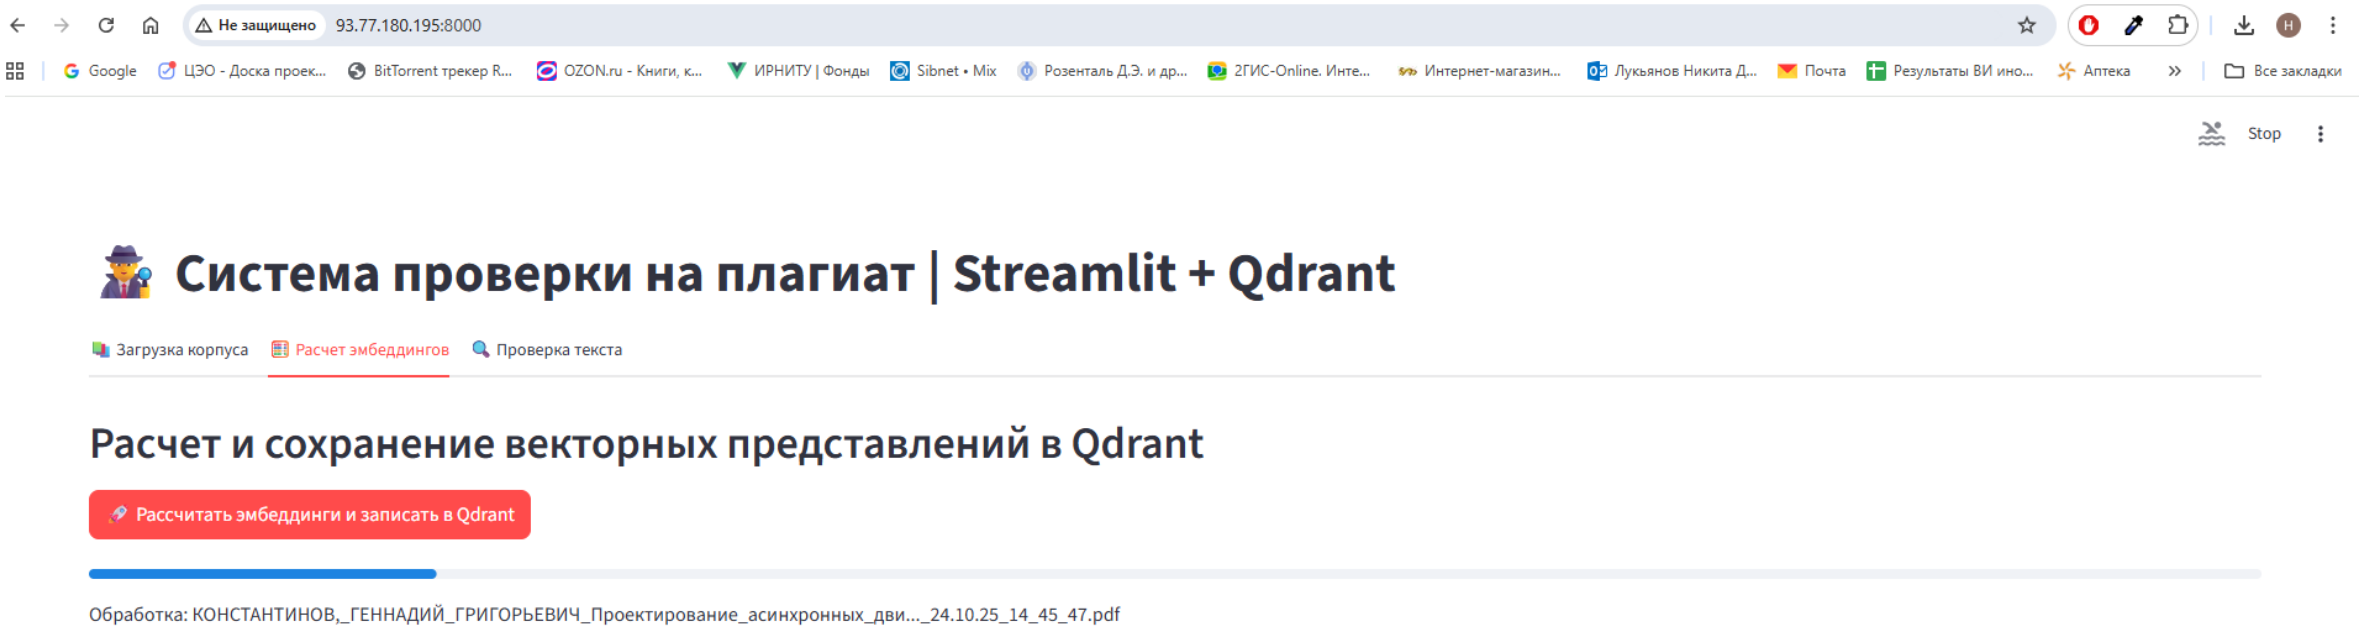

Загрузка 6 реальных работ ~21 минута

Интерфейсы приложения
Проверка работы

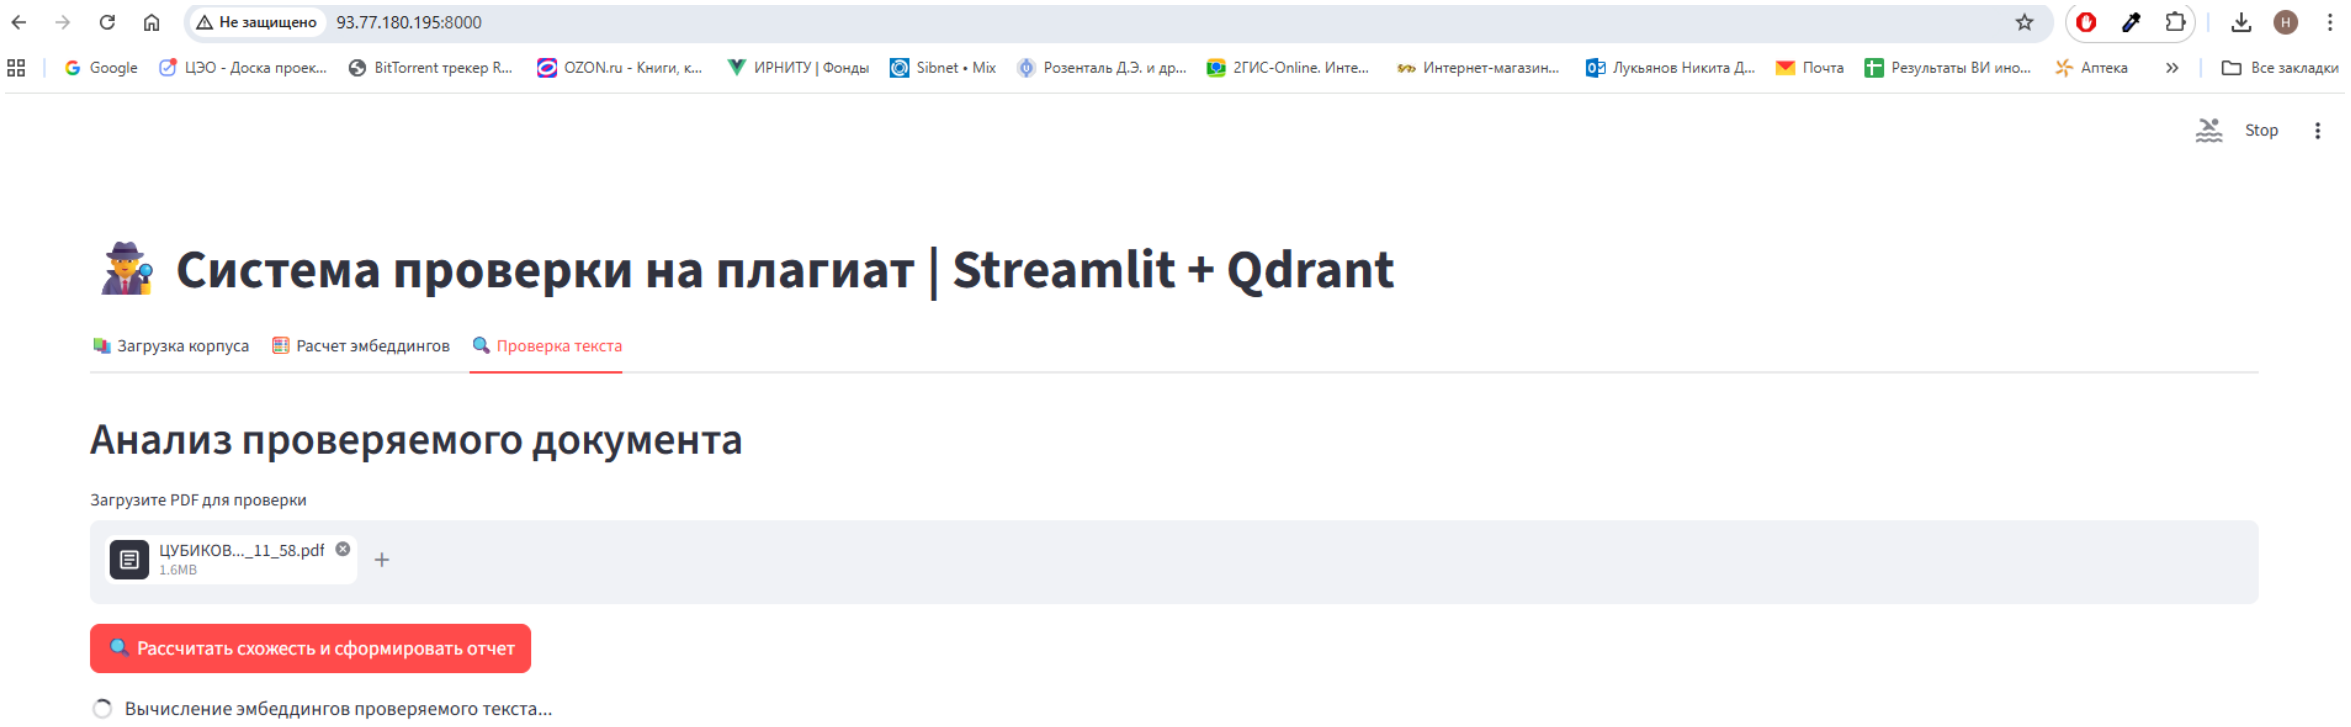

Проверка работы (190 стр.) ~1.5 минуты

Интерфейсы приложения
Проверка работы

Загрузка корпуса | Расчет эмбеддингов | Проверка текста

Анализ проверяемого документа

Загрузите PDF для проверки

Тяжелые металлы.pdf
8.5MB

Рассчитать схожесть и сформировать отчет

Отчет

Результат проверки

Предложение №2129: Схожесть с предложением №2087 из файла 'Режимы работы энергетических установок.pdf' = 0,83 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №2130: Схожесть с предложением №2082 из файла 'Режимы работы энергетических установок.pdf' = 0,61
Предложение №2131: Схожесть с предложением №2241 из файла 'Модифицированные материалы с использованием золошлаковых отходов ТЭЦ для строительства автомобильных дорог.pdf' = 0,90 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №2132: Схожесть с предложением №963 из файла 'Режимы работы энергетических установок.pdf' = 0,59
Предложение №2133: Схожесть с предложением №2087 из файла 'Режимы работы энергетических установок.pdf' = 0,83 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №2134: Схожесть с предложением №2477 из файла 'Модифицированные материалы с использованием золошлаковых отходов ТЭЦ для строительства автомобильных дорог.pdf' = 0,79
Предложение №2135: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 1,00 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №2136: Схожесть с предложением №963 из файла 'Режимы работы энергетических установок.pdf' = 0,51
Предложение №2137: Схожесть с предложением №2087 из файла 'Режимы работы энергетических установок.pdf' = 0,83 ВЫСОКАЯ СХОЖЕСТЬ

СТАТИСТИКА:
Всего предложений: 2137
Высокая схожесть (>80.0%): 1533
Процент высокой схожести: 71.74%
==========

Отчет

```
================================================================================
ОТЧЕТ О ПРОВЕРКЕ НА ПЛАГИАТ
================================================================================
Дата проверки: 08.04.2026 11:32:15
Проверяемый файл: ЦУБИКОВА,_ЛЮБОВЬ_СЕРГЕЕВНА_Правовое_обеспечение_профессио..._15.12.25_15_11_58.pdf
Всего предложений проверено: 1992

РЕЗУЛЬТАТЫ:
--------------------------------------------------------------------------------
Предложение №1: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 1,00 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №2: Схожесть с предложением №4 из файла 'Режимы работы энергетических установок.pdf' = 0,75
Предложение №3: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 1,00 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №4: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 1,00 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №5: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 1,00 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №6: Схожесть с предложением №8 из файла 'КУДРЯШОВ,_АЛЕКСАНДР_НИКОЛАЕВИЧ_Основное_и_вспомогательное_обо..._29.10.25_10_14_41.pdf' = 0,91 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №7: Схожесть с предложением №438 из файла 'Режимы работы энергетических установок.pdf' = 0,86 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №8: Схожесть с предложением №1401 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,75
Предложение №9: Схожесть с предложением №1858 из файла 'КУДРЯШОВ,_АЛЕКСАНДР_НИКОЛАЕВИЧ_Основное_и_вспомогательное_обо..._29.10.25_10_14_41.pdf' = 0,81 ВЫСОКАЯ СХОЖЕСТЬ
Предложение №10: Схожесть с предложением №1577 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,69
Предложение №11: Схожесть с предложением №361 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,74
Предложение №12: Схожесть с предложением №3652 из файла 'КУДРЯШОВ,_АЛЕКСАНДР_НИКОЛАЕВИЧ_Основное_и_вспомогательное_обо..._29.10.25_10_14_41.pdf' = 0,74
Предложение №13: Схожесть с предложением №3455 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,65
Предложение №14: Схожесть с предложением №604 из файла 'Режимы работы энергетических установок.pdf' = 0,72
Предложение №15: Схожесть с предложением №2840 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,71
Предложение №16: Схожесть с предложением №3339 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,72
Предложение №17: Схожесть с предложением №1401 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,72
```

```
Предложение №1990: Схожесть с предложением №3844 из файла 'Проектирование автоматизированных систем обработки информации и управления.pdf' = 0,64
Предложение №1991: Схожесть с предложением №1 из файла 'ЗАЛИВИН,_ВЛАДИМИР_ГРИГОРЬЕВИЧ_Технологии_проводки_скважин_в_..._02.12.25_15_48_22.pdf' = 0,64
Предложение №1992: Схожесть с предложением №1916 из файла 'Режимы работы энергетических установок.pdf' = 0,84 ВЫСОКАЯ СХОЖЕСТЬ

--------------------------------------------------------------------------------
СТАТИСТИКА:
Всего предложений: 1992
Высокая схожесть ( >80.0%): 1399
Процент высокой схожести: 70.23%
================================================================================
```

Ссылки

Проект

http://178.154.203.20:8000/

БД

http://178.154.203.20:6333/dashboard#/collections

Репозиторий

https://github.com/lukyanovnd/Fin_project_innopolis

Ноутбук

https://colab.research.google.com/drive/1W2IFyakgXZg1ZoOxVPLVxbE_hZOwUmeh?usp=sharing

ИНСТИТУТ
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
УНИВЕРСИТЕТА ИННОПОЛИС

Спасибо за внимание!

Контакты

+7(3952)405616

lukyanovnd@istu.edu

Сайт

https://www.istu.edu/person/59096